Esteganografía por Enmascaramiento con Eco

Nasser Brown, David Duarte y Jose Zúñiga

***Abstract*—This paper presents an echo-hiding system that embeds song metadata (title, artist, author, album, year, guest artist and producer) into CD-quality audio. Each window of the signal is convolved with one of two echo kernels, $h_b(n) = \delta(n) + a_b\,\delta(n - t_b)$, and the windows, which overlap with $\sin^2$ crossfades, are joined by overlap-add. The decoder computes the cepstrum autocorrelation in the spectral domain and decides, for every window, whether it carries a zero, a one or no echo at all. The system was evaluated on six 30-second tracks, namely synthetic music, rock, modern piano, classical piano, electronic music and speech. The default parameters ($t_0 = 1$ ms, $t_1 = 1.5$ ms, $a_0 = a_1 = 40$ % and a window of ten times the longest delay, or 66.8 bit/s) give the shortest window that keeps PESQ above 4.0 and recovery above 95 % on every track. With them, the bit recovery rate was between 96.4 and 100 % and PESQ was between 4.29 and 4.52 (PESQ could not evaluate the rock track). The crossfade raised PESQ by up to 1.9 points over abrupt kernel switching. Recovery and PESQ are negatively correlated ($r = -0.66$), as are transfer rate and PESQ ($r = -0.77$).**

***Palabras clave*—Autocorrelación del cepstro, Convolución, Enmascaramiento con eco, Esteganografía de audio, Solapamiento y suma.**

I. Introducción

La esteganografía es una técnica que oculta un mensaje dentro de una señal portadora, aprovechando las limitaciones de la percepción humana para que el mensaje pase inadvertido. En audio, sus aplicaciones incluyen la protección contra la piratería, las restricciones geográficas de contenido y la adición de metadatos [1], [2]. Entre las técnicas conocidas están la codificación de bit, el espectro disperso, la codificación de fase y el enmascaramiento con eco [1], [2].

El enmascaramiento con eco fue propuesto por Gruhl, Lu y Bender [3]. La idea es agregar a cada segmento del audio un eco cuyo retardo depende del bit que se quiere ocultar. Si el retardo es de alrededor de un milisegundo, el oído no distingue el eco como una repetición, sino que lo percibe como una ligera coloración del sonido, parecida a la que agrega una sala. Los autores reportaron tasas típicas de 16 bit/s y una tasa de recuperación de al menos 85 % con amplitudes de eco entre 0.3 y 0.85 veces la señal original. También observaron que el caso más difícil es el habla con pausas, porque en el silencio no hay señal que transporte el eco. Trabajos posteriores han buscado reducir la probabilidad de error de esta técnica [4].

Este trabajo implementa un sistema que oculta los metadatos de una canción (título, artista, autor, álbum, año, artista invitado y productor) en un archivo de audio con calidad de disco compacto. El sistema se construye con sistemas lineales e invariantes en el tiempo (LTI, por sus siglas en inglés). El codificador usa la convolución y el solapamiento y suma, y el decodificador usa la autocorrelación del cepstro. El prototipo se desarrolló en Python y la implementación final en C++, que produce las mismas muestras codificadas y los mismos bits decodificados que el prototipo. Los resultados que se presentan se obtuvieron con el prototipo. Además, se caracterizó el sistema con distintas amplitudes de eco, tasas de transferencia y géneros musicales.

El documento está organizado de la siguiente manera. La Sección II presenta la teoría necesaria, la Sección III describe cada módulo del sistema, la Sección IV presenta y discute los resultados, y la Sección V resume las conclusiones y el trabajo futuro.

N. Brown, D. Duarte y J. Zúñiga son estudiantes de la Maestría en Electrónica, Escuela de Ingeniería Electrónica, curso de Procesamiento Digital de Señales (correo electrónico: nasserbrown@estudiantec.cr; davidduarte@estudiantec.cr; je.zuniga@estudiantec.cr).

II. Marco teórico

II-A. Núcleos de eco y convolución

Cada bit b de valor entre 0 y 1 se codifica con el sistema LTI de la Ecuación (1):

$$H_b(z) = 1 + a_b z^{-t_b}, \qquad h_b(n) = \delta(n) + a_b\,\delta(n - t_b), \quad (1)$$

donde a_b es la amplitud y t_b el retardo del eco. La elección de estos parámetros determina el desempeño. Para retardos largos disminuyen la tasa de transferencia, mientras que retardos cortos pueden distorsionar la señal y dificultar la decodificación, además las amplitudes altas facilitan la decodificación, pero el eco puede volverse perceptible [3].

II-B. Solapamiento y suma

La señal $x(n)$ se segmenta en ventanas $v_k(n) = w_k(n)\,x(n)$ separadas L muestras, donde las funciones w_k se traslapan y cumplen $\sum_k w_k(n) = 1$. Al convolucionar una ventana con una respuesta al impulso de longitud $N = t_b + 1$, el resultado se alarga $N - 1$ muestras. Si ese excedente no se toma en cuenta, se inducen componentes espectrales parásitas que distorsionan el audio y corrompen los metadatos. En el solapamiento y suma, los excedentes y los traslapes se suman como describe la Ecuación (2):

$$y(n) = \sum_k \left(v_k * h_{b_k}\right)(n). \quad (2)$$

Si todas las ventanas usan el mismo núcleo, (2) equivale a convolucionar la señal completa, porque las w_k suman uno.

II-C. Autocorrelación del cepstro

El cepstro de una señal está dado por (3):

$$c(n) = \mathcal{F}^{-1}\left\{\ln\left(\mathcal{F}\{x(n)\}\right)\right\}. \quad (3)$$

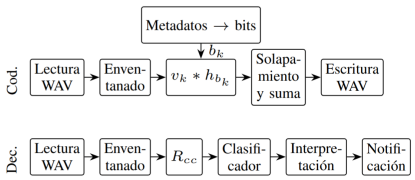


Figura 1. Diagrama general del sistema, con el codificador arriba y el decodificador abajo.

Tabla I
PARÁMETROS POR DEFECTO DEL SISTEMA

Parámetro	Valor	Equivalente
Retardo del bit 0, t_0	1000 ţs	44 muestras
Retardo del bit 1, t_1	1500 ţs	66 muestras
Amplitudes a_0, a_1	40 %	0.4
Ventana, $L = 10\,t_{\text{máx}}$	660 muestras	15.0 ms
Fundido entre núcleos	L muestras	$\sin^2$
Tasa de transferencia, f_s/L	66.8 bit/s	—
Umbral de eco, θ	3.0	—
Ventanas sin eco de cierre, G	13	195 ms

Por las propiedades de la transformada de Fourier, su autocorrelación (R_{cc}) puede evaluarse en el dominio espectral con (4):

$$R_{cc}(n) = c(n) * c(n) = \mathcal{F}^{-1}\left\{\ln\left(\mathcal{F}\{x(n)\}\right)^2\right\}. \qquad (4)$$

R_{cc} tiene la propiedad de destacar los retardos de los ecos, por lo que una ventana codificada con $h_b(n)$ presenta un pico pronunciado en $n = t_b$ [3].

II-D. Métricas de desempeño

La tasa de recuperación es la razón entre los bits decodificados correctamente y el total de bits codificados. La tasa de transferencia es de un bit por ventana, f_s/L, por lo que depende directamente del tamaño de ventana. La calidad perceptual del audio codificado se evalúa con la evaluación perceptual de la calidad de voz (PESQ, por sus siglas en inglés) [5].

III. METODOLOGÍA

La Fig. 1 muestra los dos subsistemas, y la Tabla I resume los parámetros por defecto. El audio de entrada es un archivo de formato de audio en forma de onda (WAV, por sus siglas en inglés) de 44.1 kHz, 16 bits y estéreo, y se procesa un solo canal (izquierdo por defecto).

III-A. Codificador

Los retardos, dados en microsegundos, se convierten a muestras multiplicando por f_s y redondeando al entero más cercano. El tamaño de ventana depende solo del mayor retardo, $L = 10\,t_{\text{máx}}$, y es el mismo en ambos subsistemas; la Sección IV-G justifica el factor. Cada w_k sube con una rampa $\sin^2$ de L muestras centrada en kL y baja con una rampa $\cos^2$ centrada en $(k+1)L$, de modo que el núcleo cambia de forma gradual entre bits. Cada ventana se convoluciona explícitamente con el núcleo de su bit y se combina con (2), y las ventanas posteriores al mensaje se copian sin eco. La salida se redondea y se satura al intervalo de 16 bits.

III-B. Decodificador

Para cada ventana se evalúa R_{cc} con (4) en el dominio espectral. En la implementación se usa la magnitud del espectro y se omite la fase, por lo que se puede utilizar un logaritmo con números reales en lugar de complejos. Antes de transformar, la ventana se escala a un valor eficaz de 2^{15} para que la altura de R_{cc} sea comparable entre ventanas de distinto volumen, se multiplica por una ventana de Hann y se suma una constante $\varepsilon = 10^{-12}$ dentro del logaritmo para evitar $\ln 0$.

El clasificador evalúa la magnitud de R_{cc} en t_0 y en t_1 y la compara con el nivel típico de R_{cc} en los retardos vecinos, $n \in [t_{\text{máx}}/2 + 1,\ 3t_{\text{máx}})$, mediante (5):

$$z_b = \frac{R_{cc}(t_b) - \tilde{\mu}}{d + \varepsilon}, \qquad \hat{b} = \arg\max_b z_b, \qquad (5)$$

donde $\tilde{\mu}$ es la mediana de R_{cc} en esos retardos y d la mediana de las desviaciones absolutas respecto a $\tilde{\mu}$. Si $\max_b z_b < \theta$, la ventana se clasifica como no codificada.

III-C. Protocolo de datos y notificación

Los metadatos se serializan como texto en formato de transformación de Unicode de 8 bits (UTF-8, por sus siglas en inglés) con líneas *clave=valor*, y cada byte se transmite empezando por el bit más significativo. El fin del mensaje se detecta en la primera racha de $G = 13$ ventanas consecutivas sin eco (195 ms). El intérprete agrupa los bits en bytes, separa las líneas y busca cada clave en la tabla de categorías, las reconocidas se imprimen en la salida estándar con su categoría y las desconocidas en la salida de error con una advertencia.

IV. RESULTADOS Y DISCUSIÓN

IV-A. Procedimiento experimental

Se usaron seis pistas de 30 s con géneros de características distintas, una pieza sintética formada por notas armónicas y ruido de percusión, y fragmentos de rock independiente, piano moderno, piano clásico, música electrónica y voz narrada, todos en el formato del sistema. Cada pista tiene 2004 ventanas con la configuración por defecto. En la prueba de extremo a extremo se codificaron los siete metadatos y una clave desconocida, en total 122 bytes (976 bits o 14.6 s), de modo que las 1028 ventanas finales quedan sin eco.

Además se hicieron dos barridos con bits aleatorios, uno de la amplitud entre 5 y 50 % con la tasa por defecto, y otro del tamaño de ventana entre $2\,t_{\text{máx}}$ y $32\,t_{\text{máx}}$ con 40 % de amplitud, es decir, tasas entre 20.9 y 334 bit/s. Cada punto se repitió tres veces y se reporta la mediana. Para PESQ, ambas señales se remuestrearon a 16 kHz y se compararon en modo de banda ancha. La relación entre métricas se resume con el coeficiente de correlación de Pearson, r.

IV-B. Autocorrelación del cepstro

La Fig. 2 muestra los núcleos y la R_{cc} de una ventana codificada con cada bit, expresada como la puntuación z de (5) para poder comparar las pistas. Se eligió la ventana de mayor energía de cada pista. En la pieza sintética, el rock, el piano clásico y la electrónica, el pico en el retardo del bit codificado

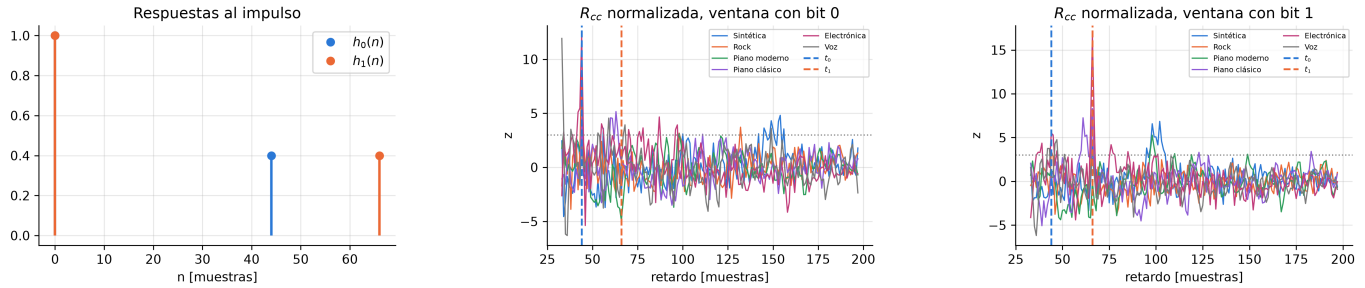


Figura 2. Respuestas al impulso de los núcleos (izquierda) y autocorrelación del cepstro de una ventana codificada con un 0 (centro) y con un 1 (derecha) en cada pista, expresada como puntuación z. Las líneas discontinuas marcan t_0 y t_1, y la línea punteada marca el umbral $\theta = 3$.

Tabla II
RESULTADOS DE EXTREMO A EXTREMO CON LOS PARÁMETROS POR DEFECTO

Pista	Recup. (%)	Errores (bits)	Eco det. (%)	Falso eco (%)	Metadatos correctos	PESQ
Sintética	100.0	0	99.9	1.8	7/7	4.29
Rock	99.8	2	99.5	6.8	5/7	—
Piano moderno	99.3	7	88.8	0.8	3/7	4.44
Piano clásico	99.7	3	100.0	8.2	6/7	4.47
Electrónica	99.8	2	98.9	24.2	5/7	4.52
Voz	96.4	35	88.8	10.0	0/7	4.50

supera el umbral $\theta = 3$, con puntuaciones entre 4.0 y 16.6, lo que confirma que R_{cc} destaca el retardo del eco. En el piano moderno y en la voz, las ventanas elegidas quedan bajo el umbral (z entre -0.1 y 2.7), por lo que se marcan como no codificadas. En las pistas con notas sostenidas aparecen otros picos, cerca de 98 muestras en el piano moderno y 102 en la pieza sintética. Provienen de la estructura periódica de la música y, aunque no coinciden con t_0 ni t_1, elevan el nivel de referencia y hacen que el eco destaque menos.

IV-C. Prueba de extremo a extremo

La Tabla II resume la decodificación con los parámetros por defecto. La tasa de recuperación fue de al menos 96.4 % en todas las pistas, por encima del mínimo de 90 %, y PESQ, calculado sobre la pista completa, quedó entre 4.29 y 4.52.

Las fallas se deben sobre todo a la interpretación del mensaje y no a la clasificación de bits. Solo la pieza sintética recuperó los siete metadatos; en las demás pistas, de 2 a 7 bits erróneos dañaron entre uno y cuatro campos, como en la electrónica, donde *title* se convirtió en *tit,e* y se reportó como desconocida. En la voz, los 35 errores dañaron todos los campos, lo que coincide con lo reportado por Gruhl *et al.* para el habla con pausas [3]. El falso eco fue bajo, salvo en la electrónica con 24.2 %, posiblemente por su contenido rítmico repetitivo, y la saturación fue despreciable, con 207 muestras (0.016 %) en el rock.

IV-D. Amplitud del eco

Según la Fig. 3, la tasa de recuperación crece con la amplitud, porque un eco más fuerte produce un pico más alto en R_{cc}. El 90 % se alcanza con 20 % de amplitud en la pieza sintética, el rock, el piano clásico y la electrónica, y con 30 % en el piano moderno y la voz. Gruhl *et al.* necesitaron entre 30 y 50 % para alcanzar 85 % [3], aunque sus pruebas incluyeron compresión y transmisión analógica.

PESQ se comporta de forma opuesta. Con 5 % está entre 4.63 y 4.64, el máximo de la escala, y con 40 % baja a valores entre 4.05 (pieza sintética) y 4.46 (electrónica). La pieza sintética es la que más se degrada, posiblemente porque sus notas puras hacen más evidente la coloración del eco. Como análisis adicional se calculó la relación señal a ruido (SNR, por sus siglas en inglés), tomando como ruido la diferencia entre la señal codificada y la original. Las seis curvas coinciden, de 26 dB con 5 % a 6 dB con 50 %, porque esa diferencia es el propio eco, una copia atenuada de la señal. La SNR no refleja la percepción, mientras que PESQ sí distingue entre pistas.

IV-E. Tasa de transferencia

En la Fig. 4, la tasa de recuperación se mantiene en al menos 95.1 % hasta 111.4 bit/s, baja a valores entre 91.6 y 98.2 % a 167 bit/s y queda entre 69.0 y 82.8 % a 334 bit/s, porque con ventanas más cortas cada bit se decide con menos muestras. PESQ también baja, de valores entre 4.50 y 4.57 a 20.9 bit/s a valores entre 1.55 y 3.92 a 334 bit/s, porque con ventanas cortas el núcleo cambia con más frecuencia y el fundido, que dura una ventana, es más rápido.

IV-F. Correlación entre las métricas

La tasa de recuperación y PESQ tienen una correlación negativa (gráfica derecha de la Fig. 4), con $r = -0.66$ en conjunto y entre -0.68 y -0.85 dentro de cada pista. Es decir, lo que hace más robusto al sistema también hace más audible el eco. La tasa de transferencia se correlaciona negativamente con PESQ ($r = -0.77$ en conjunto y entre -0.93 y -0.99 por pista) y con la tasa de recuperación ($r = -0.91$), así que aumentar la tasa empeora ambas.

IV-G. Discusión

Los resultados confirman que no es posible mejorar al mismo tiempo la robustez, la tasa y la calidad, y que cada género ubica ese compromiso en un punto distinto. Por eso los valores por defecto se eligieron con un barrido de la amplitud (15 a 45 %), del factor de ventana (6 a 16) y del fundido

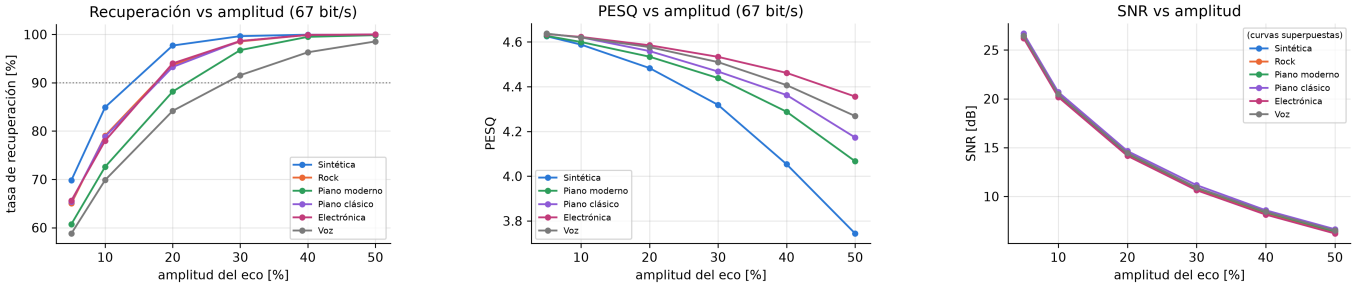


Figura 3. Efecto de la amplitud del eco a 66.8 bit/s en la tasa de recuperación (izquierda), en PESQ (centro) y en la SNR (derecha). La línea punteada marca el 90 % de recuperación.

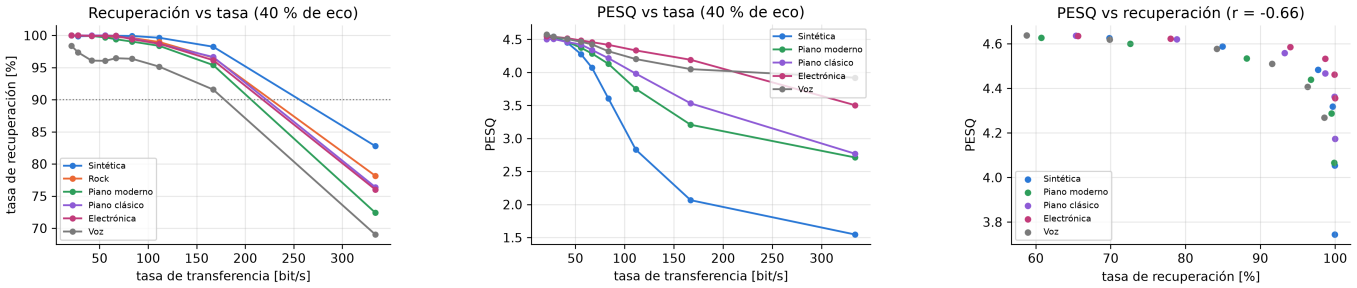


Figura 4. Tasa de recuperación (izquierda) y PESQ (centro) en función de la tasa de transferencia con 40 % de amplitud, y relación entre PESQ y la tasa de recuperación en el barrido de amplitud (derecha).

(ninguno, $L/2$ y L), con dos realizaciones de bits aleatorios, buscando la ventana más corta que mantenga PESQ ≥ 4.0 (señal perceptualmente indistinguible) y al menos 95 % de recuperación en todas las pistas, un margen sobre el mínimo de 90 %. El óptimo fue 40 % con $L = 10\,t_{\text{máx}}$ y fundido completo, con PESQ entre 4.08 y 4.47 y recuperación mínima de 96.7 %; con $9\,t_{\text{máx}}$ PESQ baja a 3.89, y con menos amplitud la voz no alcanza el 95 %. El fundido fue decisivo: con los mismos parámetros y cambio abrupto de núcleo PESQ queda entre 2.20 y 3.76, con igual recuperación.

Por último, PESQ está diseñado para voz, analiza solo hasta 8 kHz y no pudo evaluar el rock, porque su detector de actividad no encontró segmentos válidos. Sus valores sirven para comparar configuraciones, pero no como medida absoluta de calidad musical.

V. Conclusiones

La autocorrelación del cepstro, evaluada en el dominio espectral, destacó el retardo del eco, y con los parámetros por defecto la tasa de recuperación fue de 96.4 a 100 %, por encima del mínimo de 90 %.

El fundido entre núcleos elevó PESQ de valores entre 2.20 y 3.76 a valores entre 4.08 y 4.47 sin afectar la recuperación, lo que permitió usar la ventana más corta, $10\,t_{\text{máx}}$, que cumple PESQ ≥ 4.0 y 95 % de recuperación.

La tasa de recuperación crece con la amplitud del eco y PESQ disminuye. Su correlación negativa ($r = -0.66$) muestra que la robustez se obtiene a costa de la calidad perceptual. La SNR, en cambio, depende solo de la amplitud y no sirve para evaluar la calidad perceptual.

Aumentar la tasa de transferencia reduce la recuperación y PESQ. La recuperación se mantiene sobre 95 % hasta 111.4 bit/s y cae con rapidez desde 167 bit/s.

El habla con pausas es el caso más difícil, y el protocolo de datos es el punto más débil, ya que un bit erróneo basta para perder un metadato completo.

Como trabajo futuro se recomienda agregar un código corrector de errores, un encabezado con la longitud del mensaje, omitir las ventanas en silencio y confirmar la imperceptibilidad con pruebas de escucha.

Referencias

[1] P. Dutta, D. Bhattacharyya, and T. Kim, "Data hiding in audio signal: a review," *International Journal of Database Theory and Application*, vol. 2, 2009. [Online]. Available: http://www.sersc.org/journals/IJDTA/vol2_no2/1.pdf

[2] N. Kaur and S. Behal, "Audio steganography techniques – a survey," *International Journal of Engineering Research and Applications*, vol. 4, pp. 94–100, 2014. [Online]. Available: http://www.ijera.com/papers/Vol4_issue6/Version%205/P0460594100.pdf

[3] D. Gruhl, A. Lu, and W. Bender, "Echo hiding," Massachusetts Institute of Technology Media Laboratory, Reporte técnico, 1996. [Online]. Available: https://pdfs.semanticscholar.org/b964/4dbf393117b4c4bb91122cf7b08f71b71fbd.pdf

[4] V. Korzhik, "Audio watermarking based on echo hiding with zero error probability," *International Journal of Computer Science and Applications*, vol. 10, pp. 1–10, 2013. [Online]. Available: http://www.tmrfindia.org/ijcsa/v10i11.pdf

[5] ITU-T, "P.862: Perceptual evaluation of speech quality (PESQ): An objective method for end-to-end speech quality assessment of narrow-band telephone networks and speech codecs," https://www.itu.int/rec/T-REC-P.862/en, 2018.