Esteganografía por Enmascaramiento con Eco

Nasser Brown, David Duarte y Jose Zúñiga

***Abstract*—This paper presents an echo-hiding system that embeds song metadata (title, artist, author, album, year, guest artist and producer) into CD-quality audio. Each window of the signal is convolved with one of two echo kernels, $h_b(n) = \delta(n) + a_b\,\delta(n - t_b)$, and the windows are joined by overlap-add. The decoder computes the cepstrum autocorrelation in the spectral domain and decides, for every window, whether it carries a zero, a one or no echo at all. The system was evaluated on six 30-second tracks, namely synthetic music, rock, modern piano, classical piano, electronic music and speech. With the default parameters ($t_0 = 1$ ms, $t_1 = 1{,}5$ ms, $a_0 = a_1 = 40\,\%$ and 41.8 bit/s) the bit recovery rate was between 95.9 and 100 %, and the perceptual quality measured with PESQ was between 2.72 and 3.99 (PESQ could not evaluate the rock track). Recovery and PESQ are negatively correlated ($r = -0{,}75$), as are transfer rate and PESQ ($r = -0{,}66$), so robustness, speed and quality cannot be improved at the same time. Speech with pauses and strongly harmonic music were the hardest cases. The weakest component was message framing, since a single bit error corrupts a whole field. An error-correcting code and an explicit length header are proposed as future work.**

***Palabras clave*—Autocorrelación del cepstro, Convolución, Enmascaramiento con eco, Esteganografía de audio, Solapamiento y suma.**

I. Introducción

La esteganografía es una técnica que oculta un mensaje dentro de una señal portadora, aprovechando las limitaciones de la percepción humana para que el mensaje pase inadvertido. En audio, sus aplicaciones incluyen la protección contra la piratería, las restricciones geográficas de contenido y la adición de metadatos [1], [2]. Entre las técnicas conocidas están la codificación de bit, el espectro disperso, la codificación de fase y el enmascaramiento con eco [1], [2].

El enmascaramiento con eco fue propuesto por Gruhl, Lu y Bender [3]. La idea es agregar a cada segmento del audio un eco cuyo retardo depende del bit que se quiere ocultar. Si el retardo es de alrededor de un milisegundo, el oído no distingue el eco como una repetición, sino que lo percibe como una ligera coloración del sonido, parecida a la que agrega una sala. Los autores reportaron tasas típicas de 16 bit/s y una tasa de recuperación de al menos 85 % con amplitudes de eco entre 0.3 y 0.85 veces la señal original. También observaron que el caso más difícil es el habla con pausas, porque en el silencio no hay señal que transporte el eco. Trabajos posteriores han buscado reducir la probabilidad de error de esta técnica [4].

Este trabajo implementa un sistema que oculta los metadatos de una canción (título, artista, autor, álbum, año, artista invitado y productor) en un archivo de audio con calidad de disco compacto. El sistema se construye con sistemas lineales e invariantes en el tiempo (LTI, por sus siglas en inglés). El codificador usa la convolución y el solapamiento y suma, y el decodificador usa la autocorrelación del cepstro. El prototipo se desarrolló en Python y la implementación final en C++. Los resultados que se presentan se obtuvieron con el prototipo. Además, se caracterizó el sistema con distintas amplitudes de eco, tasas de transferencia y géneros musicales.

El documento está organizado de la siguiente manera. La Sección II presenta la teoría necesaria, la Sección III describe cada módulo del sistema, la Sección IV presenta y discute los resultados, y la Sección V resume las conclusiones y el trabajo futuro.

N.Brown, D. Duarte y J. Zuñiga son estudiantes de la Maestría en Electrónica, Escuela de Ingeniería Electrónica, curso de Procesamiento Digital de Señales (correo electrónico: nasserbrown@estudiantec.cr; davidduarte@estudiantec.cr; je.zuniga@estudiantec.cr).

II. Marco teórico

II-A. Núcleos de eco y convolución

Cada bit b de valor entre 0 y 1 se codifica con el sistema LTI de la ecuación (1):

$$H_b(z) = 1 + a_b z^{-t_b}, \qquad h_b(n) = \delta(n) + a_b\,\delta(n - t_b), \quad (1)$$

donde a_b es la amplitud y t_b el retardo del eco. La elección de estos parámetros determina el desempeño. Para retardos largos disminuyen la tasa de transferencia, mientras que retardos cortos pueden distorsionar la señal y dificultar la decodificación, además las amplitudes altas facilitan la decodificación, pero el eco puede volverse perceptible [3].

II-B. Solapamiento y suma

La señal $x(n)$ se segmenta en ventanas $v_k(n)$ de longitud L. Al convolucionar una ventana con una respuesta al impulso de longitud $N = t_b + 1$, el resultado tiene longitud $L + N - 1$. Si el excedente de $N - 1$ muestras no se toma en cuenta, se inducen componentes espectrales parásitas que distorsionan el audio y corrompen los metadatos. En el solapamiento y suma, ese excedente se suma al inicio de la siguiente ventana como describe la ecuación (2):

$$y(n) = \sum_k \left(v_k * h_{b_k}\right)(n - kL). \quad (2)$$

II-C. Autocorrelación del cepstro

El cepstro de una señal está dado por (3):

$$c(n) = \mathcal{F}^{-1}\left\{\ln\left(\mathcal{F}\{x(n)\}\right)\right\}. \quad (3)$$

Por las propiedades de la transformada de Fourier, su autocorrelación (R_{cc}) puede evaluarse en el dominio espectral con (4):

$$R_{cc}(n) = c(n) * c(n) = \mathcal{F}^{-1}\left\{\ln\left(\mathcal{F}\{x(n)\}\right)^2\right\}. \quad (4)$$

R_{cc} tiene la propiedad de destacar los retardos de los ecos, por lo que una ventana codificada con $h_b(n)$ presenta un pico pronunciado en $n = t_b$ [3].

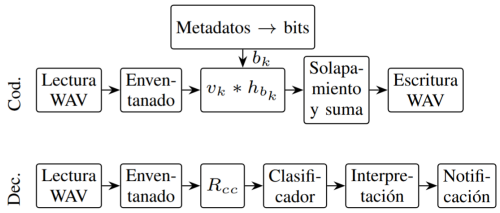


Figura 1. Diagrama general del sistema, con el codificador arriba y el decodificador abajo.

Tabla I
PARÁMETROS POR DEFECTO DEL SISTEMA

Parámetro	Valor	Equivalente
Retardo del bit 0, t_0	1000 µs	44 muestras
Retardo del bit 1, t_1	1500 µs	66 muestras
Amplitudes a_0, a_1	40 %	0.4
Ventana, $L = 16\,t_{\text{máx}}$	1056 muestras	23.9 ms
Tasa de transferencia, f_s/L	41.8 bit/s	—
Umbral de eco, θ	3.0	—
Ventanas sin eco de cierre, G	8	191 ms

II-D. Métricas de desempeño

La tasa de recuperación es la razón entre los bits decodificados correctamente y el total de bits codificados. La tasa de transferencia es de un bit por ventana, f_s/L, por lo que depende directamente del tamaño de ventana. La calidad perceptual del audio codificado se evalúa con la evaluación perceptual de la calidad de voz (PESQ, por sus siglas en inglés) [5].

III. METODOLOGÍA

La Fig. 1 muestra los dos subsistemas, y la Tabla I resume los parámetros por defecto. El audio de entrada es un archivo de formato de audio en forma de onda (WAV, por sus siglas en inglés) de 44.1 kHz, 16 bits y estéreo, y se procesa un solo canal (izquierdo por defecto).

III-A. Codificador

Los retardos, dados en microsegundos, se convierten a muestras multiplicando por f_s y redondeando al entero más cercano. El tamaño de ventana depende solo del mayor retardo, $L = 16\,t_{\text{máx}}$, y es el mismo en ambos subsistemas. Cada ventana se convoluciona explícitamente con el núcleo de su bit y se combina con (2), las ventanas posteriores al mensaje se copian sin eco. La salida se redondea y se satura al intervalo de 16 bits.

III-B. Decodificador

Para cada ventana se evalúa R_{cc} con (4) en el dominio espectral. En la implementación se usa la magnitud del espectro y se omite la fase, por lo que se puede utilizar un logaritmo con números reales en lugar de complejos. Antes de transformar, la ventana se escala a un nivel fijo para que la altura de R_{cc} sea comparable entre ventanas de distinto volumen, se multiplica por una ventana de Hann y se suma una constante $\varepsilon = 10^{-12}$ dentro del logaritmo para evitar $\ln 0$.

El clasificador evalúa la magnitud de R_{cc} en t_0 y en t_1 y la compara con el nivel típico de R_{cc} en los retardos vecinos, $n \in [t_{\text{máx}}/2 + 1,\, 3t_{\text{máx}})$, mediante (5):

$$z_b = \frac{R_{cc}(t_b) - \tilde{\mu}}{d + \varepsilon}, \qquad \hat{b} = \arg\max_b z_b, \tag{5}$$

donde $\tilde{\mu}$ es la mediana de R_{cc} en esos retardos y d la mediana de las desviaciones absolutas respecto a $\tilde{\mu}$. Si $\max_b z_b < \theta$, la ventana se clasifica como no codificada.

III-C. Protocolo de datos y notificación

Los metadatos se serializan como texto UTF-8 con líneas *clave=valor*, y cada byte se transmite empezando por el bit más significativo. El fin del mensaje se detecta en la primera racha de $G = 8$ ventanas consecutivas sin eco. El intérprete agrupa los bits en bytes, separa las líneas y busca cada clave en la tabla de categorías, las reconocidas se imprimen en la salida estándar con su categoría y las desconocidas en la salida de error con una advertencia.

IV. RESULTADOS Y DISCUSIÓN

IV-A. Procedimiento experimental

Se usaron seis pistas de 30 s con géneros de características distintas, una pieza sintética formada por notas armónicas y ruido de percusión, y fragmentos de rock independiente, piano moderno, piano clásico, música electrónica y voz narrada, todos en el formato del sistema. Cada pista tiene 1252 ventanas con la configuración por defecto. En la prueba de extremo a extremo se codificaron los siete metadatos y una clave desconocida, en total 122 bytes (976 bits o 23.4 s), de modo que las 276 ventanas finales quedan sin eco.

Además se hicieron dos barridos con bits aleatorios, uno de la amplitud entre 5 y 50 % con la tasa por defecto, y otro del tamaño de ventana entre $2\,t_{\text{máx}}$ y $32\,t_{\text{máx}}$ con 40 % de amplitud, es decir, tasas entre 20.9 y 334 bit/s. Cada punto se repitió tres veces y se reporta la mediana. Para PESQ, ambas señales se remuestrearon a 16 kHz y se compararon en modo de banda ancha. La relación entre métricas se resume con el coeficiente de correlación de Pearson, r.

IV-B. Autocorrelación del cepstro

La Fig. 2 muestra los núcleos y la R_{cc} de una ventana codificada con cada bit, expresada como la puntuación z de (5) para poder comparar las pistas. Se eligió la ventana de mayor energía de cada pista. En la pieza sintética, el rock, el piano clásico y la electrónica, el pico en el retardo del bit codificado supera con claridad el umbral $\theta = 3$, con puntuaciones entre 5.2 y 13.8, lo que confirma que R_{cc} destaca el retardo del eco. En el piano moderno y en la voz, una de las dos ventanas queda bajo el umbral ($z = 1{,}2$ y $z = 1{,}4$). El bit se decide bien, porque el valor en el retardo correcto sigue siendo el mayor, pero la ventana se marca como no codificada. En las pistas con notas sostenidas aparecen otros picos, cerca de 87 muestras en el piano clásico, 98 en el piano moderno y 102 en la pieza sintética. Provienen de la estructura periódica de la música y, aunque no coinciden con t_0 ni t_1, elevan el nivel de referencia y hacen que el eco destaque menos.

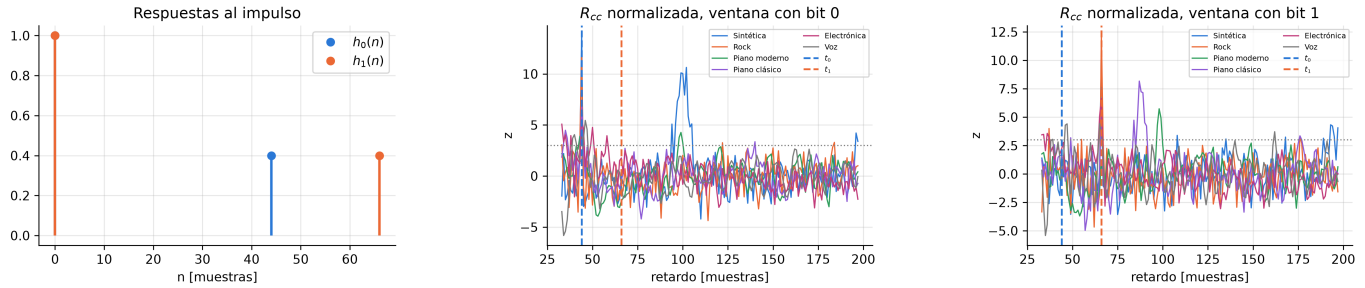


Figura 2. Respuestas al impulso de los núcleos (izquierda) y autocorrelación del cepstro de una ventana codificada con un 0 (centro) y con un 1 (derecha) en cada pista, expresada como puntuación z. Las líneas discontinuas marcan t_0 y t_1, y la línea punteada marca el umbral $\theta = 3$.

Tabla II
RESULTADOS DE EXTREMO A EXTREMO CON LOS PARÁMETROS POR DEFECTO

Pista	Recup. (%)	Errores (bits)	Eco det. (%)	Falso eco (%)	Metadatos correctos	PESQ
Sintética	100.0	0	100.0	1.1	7/7	2.72
Rock	99.9	1	100.0	3.3	6/7	—
Piano moderno	99.3	7	73.2	0.4	1/7	3.16
Piano clásico	100.0	0	100.0	5.1	7/7	3.74
Electrónica	99.9	1	99.7	20.3	7/7	3.85
Voz	95.9	40	87.6	4.3	0/7	3.99

IV-C. Prueba de extremo a extremo

La Tabla II resume la decodificación con los parámetros por defecto. La tasa de recuperación fue de al menos 95.9 % en todas las pistas, por encima del mínimo de 90 %. La pieza sintética, el piano clásico y la electrónica recuperaron los siete metadatos, y su salida de error mostró solo la advertencia esperada por la clave desconocida. El PESQ de la tabla se calculó sobre la pista completa.

Las fallas se deben sobre todo a la interpretación del mensaje y no a la clasificación de bits. En el rock, un solo bit erróneo cambió la clave *album* por *albUm*, que se reportó como desconocida. En el piano moderno, el 26.8 % de las ventanas codificadas quedó bajo el umbral, ocho de ellas seguidas bastaron para declarar el fin del mensaje en la ventana 719 de 976, y solo el álbum llegó intacto. En la voz, 389 de las 1252 ventanas están prácticamente en silencio, 297 de ellas dentro del mensaje, y los 40 errores dañaron todos los campos, lo que coincide con lo reportado por Gruhl *et al.* para el habla con pausas [3]. Las ventanas sin codificar confundidas con ventanas codificadas (falso eco) fueron pocas, salvo en la electrónica con 20.3 %, posiblemente por su contenido rítmico repetitivo. La saturación fue despreciable, con 324 muestras (0.024 %) en el rock y 6 en el piano moderno.

IV-D. Amplitud del eco

Según la Fig. 3, la tasa de recuperación crece con la amplitud, porque un eco más fuerte produce un pico más alto en R_{cc}. El 90 % se alcanza con 10 % de amplitud en la pieza sintética, entre 10 y 20 % en el rock, el piano clásico y la electrónica, con 20 % en el piano moderno y con 30 % en la voz. Gruhl *et al.* necesitaron entre 30 y 50 % para alcanzar 85 % [3], aunque sus pruebas incluyeron compresión y transmisión analógica.

PESQ se comporta de forma opuesta. Con 5 % está entre 4.52 y 4.62, cerca del máximo de 4.64, y con 40 % baja a valores entre 2.44 (pieza sintética) y 3.85 (voz). La pieza sintética es la que más se degrada, posiblemente porque sus notas puras hacen más evidente la coloración del eco, y la voz la que menos, porque sus pausas no se modifican. Como análisis adicional se calculó la relación señal a ruido (SNR, por sus siglas en inglés), tomando como ruido la diferencia entre la señal codificada y la original. Las seis curvas coinciden, de 26 dB con 5 % a 6 dB con 50 %, porque esa diferencia es el propio eco, una copia atenuada de la señal. La SNR no refleja la percepción, mientras que PESQ sí distingue entre pistas.

IV-E. Tasa de transferencia

En la Fig. 4, la tasa de recuperación se mantiene en al menos 95.8 % hasta 83.5 bit/s, baja a valores entre 85.1 y 98.3 % a 167 bit/s y queda entre 62.6 y 80.8 % a 334 bit/s, porque con ventanas más cortas cada bit se decide con menos muestras. PESQ también baja, de valores entre 2.80 y 4.12 a 20.9 bit/s a valores entre 1.38 y 2.91 a 334 bit/s. Con ventanas cortas el codificador cambia de núcleo con más frecuencia, y es posible que esos cambios se perciban como una degradación adicional.

IV-F. Correlación entre las métricas

La tasa de recuperación y PESQ tienen una correlación negativa (gráfica derecha de la Fig. 4), con $r = -0{,}75$ en conjunto y entre $-0{,}75$ y $-0{,}93$ dentro de cada pista. Es decir, lo que hace más robusto al sistema también hace más audible el eco. La tasa de transferencia se correlaciona negativamente con PESQ ($r = -0{,}66$ en conjunto y entre $-0{,}91$ y $-0{,}96$ por pista) y con la tasa de recuperación ($r = -0{,}93$), así que aumentar la tasa empeora ambas. Las correlaciones en conjunto son más débiles porque cada género tiene su propio nivel de PESQ.

IV-G. Discusión

Los resultados confirman que no es posible mejorar al mismo tiempo la robustez, la tasa y la calidad, y que cada género ubica ese compromiso en un punto distinto. Los valores por defecto cumplen la recuperación mínima, pero la calidad

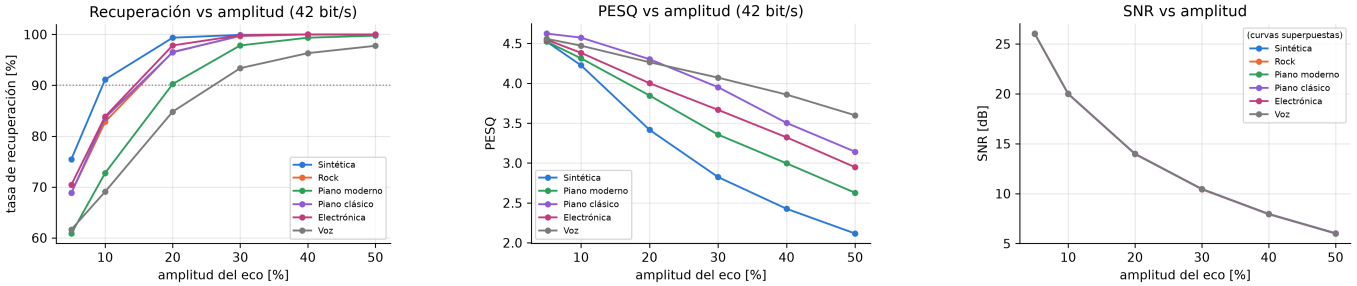


Figura 3. Efecto de la amplitud del eco a 41.8 bit/s en la tasa de recuperación (izquierda), en PESQ (centro) y en la SNR (derecha). La línea punteada marca el 90 % de recuperación.

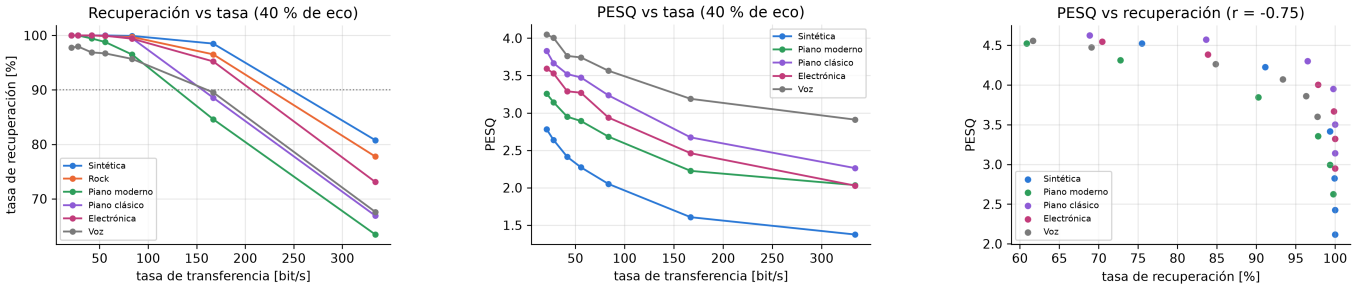


Figura 4. Tasa de recuperación (izquierda) y PESQ (centro) en función de la tasa de transferencia con 40 % de amplitud, y relación entre PESQ y la tasa de recuperación en el barrido de amplitud (derecha).

de la pieza sintética y del piano moderno es moderada. Con 30 % de amplitud, todas las pistas mantendrían al menos 92.6 % de recuperación y PESQ subiría entre 0.26 y 0.40, por lo que ese valor parece un mejor equilibrio. A 83.5 bit/s la capacidad se duplicaría sin bajar de 95.8 % de recuperación, a cambio de perder entre 0.26 y 0.45 de PESQ.

El componente más frágil es el protocolo de datos, porque un bit erróneo daña un campo completo y la detección del fin falla tanto con ventanas codificadas débiles como con ecos falsos. Por último, PESQ está diseñado para voz, analiza solo hasta 8 kHz y no pudo evaluar el rock, porque su detector de actividad no encontró segmentos válidos. Sus valores sirven para comparar configuraciones, pero no como medida absoluta de calidad musical.

V. Conclusiones

La autocorrelación del cepstro, evaluada en el dominio espectral, destacó el retardo del eco, y con los parámetros por defecto la tasa de recuperación fue de 95.9 a 100 %, por encima del mínimo de 90 %.

La tasa de recuperación crece con la amplitud del eco y PESQ disminuye. Su correlación negativa ($r = -0{,}75$) muestra que la robustez se obtiene a costa de la calidad perceptual. La SNR, en cambio, depende solo de la amplitud y no sirve para evaluar la calidad perceptual.

Aumentar la tasa de transferencia reduce la recuperación y PESQ. La recuperación se mantiene sobre 95 % hasta 83.5 bit/s y cae con rapidez desde 167 bit/s.

La música densa es el caso más favorable, la música armónica reduce la confianza del clasificador y el habla con pausas es el caso más difícil.

El protocolo de datos es el punto más débil, ya que un bit erróneo o una racha de ventanas débiles basta para perder metadatos completos.

Como trabajo futuro se recomienda agregar un código corrector de errores, un encabezado con la longitud del mensaje, omitir las ventanas en silencio, suavizar la transición entre núcleos, reducir la amplitud por defecto a 30 % y validar la implementación en C++ contra el prototipo.

Referencias

[1] P. Dutta, D. Bhattacharyya, and T. Kim, "Data hiding in audio signal: a review," *International Journal of Database Theory and Application*, vol. 2, 2009. [Online]. Available: http://www.sersc.org/journals/IJDTA/vol2_no2/1.pdf

[2] N. Kaur and S. Behal, "Audio steganography techniques – a survey," *International Journal of Engineering Research and Applications*, vol. 4, pp. 94–100, 2014. [Online]. Available: http://www.ijera.com/papers/Vol4_issue6/Version%205/P0460594100.pdf

[3] D. Gruhl, A. Lu, and W. Bender, "Echo hiding," Massachusetts Institute of Technology Media Laboratory, Technical report. [Online]. Available: https://pdfs.semanticscholar.org/b964/4dbf393117b4c4bb91122cf7b08f71b71fbd.pdf

[4] V. Korzhik, "Audio watermarking based on echo hiding with zero error probability," *International Journal of Computer Science and Applications*, vol. 10, pp. 1–10, 2013. [Online]. Available: http://www.tmrfindia.org/ijcsa/v10i11.pdf

[5] ITU Radiocommunication Assembly, "P.862: Perceptual evaluation of speech quality (PESQ): An objective method for end-to-end speech quality assessment of narrow-band telephone networks and speech codecs," https://www.itu.int/rec/T-REC-P.862/en, 2018.